

Guía para el desarrollo del proyecto del curso

Julián D. Arias-Londoño

*Dpto. of Systems Engineering and Computer Science
Universidad de Antioquia*

Resumen

Las actividades propuestas para el desarrollo del proyecto buscan que cada uno de los grupos de estudiantes aborden todo el análisis, el diseño, y la simulación de un sistema de predicción basado en técnicas de aprendizaje de máquina; describiendo el problema, evaluando sus similitudes con otros proyectos y soluciones reportados en la literatura especializada, especificando cada una de las etapas del desarrollo del trabajo, los modelos usados con sus respectivas restricciones, el ajuste de hiperparámetros, la metodología de validación, los resultados de las simulaciones y las conclusiones obtenidas.

Índice

1. Introducción	1	técnicas y aproximaciones vistas en el curso de Modelos y Simulación II. Los problemas abordados pueden ser propuestos por el grupo de estudiantes, o seleccionados a partir del listado que será compartido por el profesor del curso. Sólo se permite que un proyecto/dataset sea desarrollado por un equipo de trabajo. El listado de proyectos sugeridos puede ser consultado en el siguiente enlace .
2. Descripción del problema (10 %)	2	
3. Estado del arte (10 %)	2	
4. Entrenamiento y Evaluación de los Modelos (15 %)	3	
4.1. Configuración experimental . . .	3	
4.2. Resultados del entrenamiento de Modelos	3	
5. Reducción de dimensión (15 %)	3	
5.1. Análisis individual de variables	3	
5.2. Extracción de características lineal	4	
5.3. Extracción de características no lineal	4	
6. Evaluación (50 %)	4	

1. Introducción		Cada equipo de trabajo debe crear un repositorio de GitHub en el que se alojen un reporte del proyecto (en formato pdf) y, al menos, un notebook en el que se puedan reproducir los resultados incluidos en el reporte. El readme del repositorio debe proporcionar instrucciones claras sobre cómo interactuar correctamente con él. Para el reporte se debe usar la plantilla IEEE para los artículos publicados en Transactions. Se recomienda usar un editor de texto $\text{\LaTeX}$, en particular Overleaf . Tanto el reporte como el/los notebooks deben incluir las secciones descritas a continuación.
-----------------	--	---

Cada equipo de trabajo debe seleccionar un problema que pueda abordarse a partir de las

2. Descripción del problema (10 %)

La primera parte del informe está destinada a describir el problema, realizar un análisis exploratorio de los datos que permita comprender la composición de la base de datos y definir la aproximación que, desde el punto de vista de *Machine Learning* - *ML*, seguirá el equipo para resolver el problema. Todos los informes deben contener:

1. Una descripción clara del contexto del problema, que evidencie la utilidad de desarrollar una solución basada en ML para dicho problema.
2. Una descripción de la composición de la base de datos incluyendo (pero no limitándose a) el número de muestras, el número de variables, su significado, la existencia de datos faltantes y, si es del caso, la estrategia de imputación de datos seguida. Además, debe describirse claramente el tipo de codificación utilizado para las diferentes variables del problema.
3. El tipo de configuración o paradigma de aprendizaje que el equipo de trabajo decidió como apropiado para abordar el problema y su justificación.

3. Estado del arte (10 %)

El propósito fundamental de esta fase del proyecto es que los grupos de trabajo revisen literatura especializada del campo de ML en la que se presenten soluciones a problemas similares al descrito en la sección 2.

4. Realice una búsqueda de al menos 4 artículos que hayan abordado el mismo problema que Uds. están trabajando. Incluya, en la medida de lo posible, trabajos que hayan empleado la misma base de datos. Describa brevemente:
 - ¿Qué configuración o paradigma de aprendizaje se usa en el trabajo?
 - ¿Qué técnica(s) de aprendizaje usan los autores para solucionar el problema planteado?
 - ¿Qué metodología de validación usaron?
 - ¿Cuáles fueron las métricas empleadas para evaluar el desempeño del sistema? En caso de que alguna métrica no haya sido vista en clase, se debe describir en qué consiste y presentar su definición matemática.
 - ¿Cuáles fueron los resultados obtenidos en cada uno de los trabajos citados?
- Se recomienda buscar trabajos en las bases de datos: [Elsevier](#) y [IEEE](#). También se pueden buscar trabajos en la base de datos [Springer Nature](#), pero se debe tener en cuenta que el acceso que tiene la Universidad a dicha base de datos es mucho más limitado. Incluir preferiblemente artículos publicados en revistas, no en congresos ni conferencias. Se recomienda utilizar el buscador [Google Scholar](#) para encontrar artículos que hayan citado la base de datos seleccionada. **No utilice más de una página del informe para esta descripción.**

4. Entrenamiento y Evaluación de los Modelos (15 %)

En esta sección se debe describir el diseño experimental y los resultados obtenidos en las simulaciones.

4.1. Configuración experimental

5. Describa la metodología de validación seleccionada para entrenar y evaluar los modelos de ML. En caso de requerir etapas adicionales, como la utilización de técnicas de submuestreo o sobremuestreo, la forma en la que fueron usadas debe estar descrita en este apartado.

6. Incluya una tabla en la que especifique el conjunto de hiperparámetros analizados durante el proceso de evaluación de cada modelo, junto con la descripción de la malla de valores utilizada para cada uno. Cada proyecto debe comparar al menos 5 modelos de aprendizaje, entre los que se deben incluir:

- Un modelo paramétrico basado en funciones discriminantes gaussianas o en regresión (lineal o logística según se requiera).
- Un modelo no paramétrico
- Un modelo basado en el ensamble de árboles de decisión
- Una red neuronal artificial

- Una máquina de vectores de soporte

7. Describa las métricas de desempeño que se utilizarán para evaluar el sistema y justifique su uso.

4.2. Resultados del entrenamiento de Modelos

8. Presente los resultados de la experimentación para cada uno de los modelos evaluados, en los que se evidencie el efecto de los hiperparámetros en el desempeño del modelo. Haga uso de tablas y gráficas que ayuden al lector a comprender con claridad los resultados. **TODAS** las figuras y tablas deben ser introducidas en el texto del informe y contener un *caption* que las describa. Todas las figuras deben incluir los nombres de los ejes para que el lector comprenda la información que se le presenta. Las medidas de desempeño deben incluir los intervalos de confianza correspondientes estimados durante la fase de validación. **Recuerde incluir los resultados de entrenamiento, validación y test.**

5. Reducción de dimensión (15 %)

En esta fase del proyecto, se deben evaluar diferentes técnicas de reducción de dimensionalidad y determinar si es posible reducir la complejidad del modelo final.

5.1. Análisis individual de variables

9. Realice un análisis individual de cada una de las características, a partir de medidas de correlación y/o de índice de discriminación que reflejen la

capacidad discriminativa de las variables (según corresponda). Identifique, de acuerdo con este análisis, si existen y cuáles son las características candidatas a ser eliminadas.

5.2. Extracción de características lineal

10. Use el método PCA para encontrar un conjunto de componentes principales con un número de componentes inferior al de variables originales y evalúe nuevamente los 2 mejores modelos de predicción encontrados en la sección 4. Cada grupo debe decidir el criterio para seleccionar el número de componentes principales y justificar su decisión. Incluya una tabla con los resultados, indicando el porcentaje de reducción alcanzado y las demás medidas de desempeño.

5.3. Extracción de características no lineal

11. Use el método UMAP para encontrar un conjunto de componentes con un ta-

maño inferior al número de variables original y evalúe nuevamente los 2 mejores modelos de predicción encontrados en la sección 4. Cada grupo debe decidir el criterio para seleccionar el número de componentes y justificar su decisión. Incluya una tabla con los resultados, indicando el porcentaje de reducción alcanzado y las demás medidas de desempeño.

12. Incluya una sección de discusión y conclusiones que evalúe de forma completa la solución desarrollada, y compare sus resultados con los descritos en la sección 3.

Recuerde, cuando se cambia el espacio de características se debe realizar un nuevo ajuste de hiperparámetros. Los encontrados en la fase anterior no tienen por qué ser óptimos en el nuevo espacio de características.

6. Evaluación (50 %)

Para la evaluación final del proyecto se tendrán en cuenta los siguientes criterios:

- Alcance de los objetivos de las secciones anteriores.
- No superar las **10 páginas** en el reporte.
- Orden y claridad del repositorio de GitHub para reproducir los resultados.
- Sustentación: cada grupo debe preparar un video de 10 minutos que presente un

resumen del proyecto. El video se proyectará durante una sesión de clase y los estudiantes deberán responder a las preguntas del público. La capacidad de cada integrante del grupo de responder a las preguntas será evaluada de manera individual.

Nota: Las secciones 2 y 3 serán evaluadas en la primera entrega de avance del proyecto.